

Auditoría del backend, arquitectura y agentes

Documento de verificación contra TG1_ChristianMendoza.pdf. La auditoría parte de una línea base con análisis estático limpio y 17 pruebas automatizadas aprobadas.

Conclusión ejecutiva

El backend materializa el monolito modular FastAPI, el orquestador central y los cuatro agentes del diseño. La extensión incorpora conocimiento RAG versionado, embeddings locales/Supabase, evidencia por respuesta y fallback humano. Los puntos que dependen del frontend continúan sin verificación porque la interfaz existente usa mocks.

Correspondencia arquitectónica

Interacción: endpoints de kiosco y credenciales efímeras. Privacidad: PIIMaskingService. Orquestación: OrchestratorService. Agentes: clasificación, priorización, derivación y atención inicial. Persistencia: SQLAlchemy sobre PostgreSQL/pgvector. Visualización: endpoints ejecutivos y gerenciales. Conocimiento: repositorio RAG usado por atención inicial.

Requerimientos funcionales

ID	Requisito	Estado	Evidencia / observación
RF-01	Voz en español	Parcial	Token Realtime disponible; frontend actual simulado.
RF-02	Confirmación	Cumple	Resumen, confirmación y corrección implementados.
RF-03	Clasificación	Cumple	Cinco categorías bancarias estructuradas.
RF-04	Desambiguación	Cumple	Preguntas breves con límite configurable.
RF-05	Enmascaramiento PII	Parcial	PII local antes de análisis; audio llega al transcriptor.
RF-06	Priorización	Cumple	Reglas, señales de riesgo y atención preferente.
RF-07	Casos críticos	Cumple	Fraude y bloqueo activan prioridad alta/crítica.
RF-08	Atención inicial	Cumple	RAG con evidencia o derivación humana.
RF-09	Derivación	Cumple	Perfil, embedding, experiencia y carga.
RF-10	Ticket y trazabilidad	Cumple	Ticket, estados y eventos auditables.
RF-11	Vista operativa	Cumple	Listado y detalle con control por ejecutivo.
RF-12	Vista gerencial	Cumple	Métricas, filtros y casos agregados.
RF-13	Reclamo	Cumple	Corpus BMSC/ASFI y seguimiento en resultado.

ID	Requisito	Estado	Evidencia / observación
RF-14	Atención preferente	Cumple	Marca y elevación controlada de prioridad.
RF-15	Identificación básica	Cumple	Identificador ficticio solicitado por nivel.
RF-16	Validación demostrativa	Cumple	Hash contra clientes de demostración.
RF-17	Control de respuesta	Cumple	Solo consultas generales admiten automatización.

Requerimientos no funcionales

ID	Requisito	Estado	Evidencia / observación
RNF-01	Usabilidad	No verificable	Depende del frontend, fuera de este alcance.
RNF-02	Privacidad	Parcial	Minimización y masking; transcripción es externa.
RNF-03	Seguridad de acceso	Cumple	JWT, sesión de kiosco y roles.
RNF-04	Auditoría	Cumple	Eventos y trazas RAG sin texto original.
RNF-05	Disponibilidad	Cumple	Fallback conservador y derivación ante fallo RAG.
RNF-06	Rendimiento	Cumple	Timeouts, batching, índice HNSW y top-k.
RNF-07	Modularidad	Cumple	Agentes, orquestador, repositorios y conocimiento.
RNF-08	Escalabilidad lógica	Cumple	Corpus versionado y reglas configurables.
RNF-09	Mantenibilidad	Cumple	CLI reproducible, tipado y pruebas.
RNF-10	Accesibilidad	No verificable	Corresponde a la interfaz web.
RNF-11	Alcance académico	Cumple	Datos ficticios, sin core bancario.
RNF-12	Cumplimiento documental	Cumple	Matriz, PDFs, fuentes y evaluación.
RNF-13	Minimización	Cumple	Hashes e identificadores enmascarados.
RNF-14	Identificación/autenticación	Cumple	Separación explícita en dominio y voz.
RNF-15	Exposición por rol	Cumple	Resúmenes enmascarados y métricas agregadas.

Controles de grounding

Una respuesta automática exige recuperación sobre consulta enmascarada, umbral mínimo, salida estructurada y referencias a chunks recuperados. Si falta evidencia, el modelo no responde y el caso se deriva. Realtime no crea respuestas autónomas.

Limitaciones conocidas

La transcripción de voz requiere enviar audio a OpenAI antes del enmascaramiento. Supabase necesita cadenas PostgreSQL adicionales a SUPABASE_URL y la service-role key. La veracidad de contenido

simulado depende de la política del corpus; RAG garantiza restricción a evidencia, no que una regla simulada represente una política bancaria real.